Введение в статистику

Как сравнивать группы и принимать решения по данным

Сафронова Наталья
hh.ru
3 ноября 2026 г.

Расширенная версия лекции для самостоятельного чтения

Оглавление

1 Зачем аналитике статистика 1
- 1.1 Типичный вопрос аналитика . . . 1
- 1.2 От данных к решению . . . 1

2 Гипотезы, ошибки и мощность 2
- 2.1 Язык проверки гипотез . . . 2
- 2.2 Сначала одна группа и эффект . . . 3
- 2.3 p-value в картинках . . . 4
- 2.4 Что делает проверку гипотез чувствительной . . . 6

3 Доверительные интервалы 8
- 3.1 Эффект без интервала - неполный ответ . . . 8
- 3.2 Стандартная ошибка среднего . . . 8
- 3.3 Практическая интерпретация . . . 9

4 Методы для статистических проверок 10
- 4.1 Центральная предельная теорема . . . 10
- 4.2 z-test . . . 10
- 4.3 t-test . . . 11
- 4.4 Welch t-test: сравниваем средние . . . 12
- 4.5 t-test: когда хорош, а когда нет . . . 13
- 4.6 t-test в Python . . . 13
- 4.7 Критерий Манна-Уитни . . . 14
- 4.8 Bootstrap: серебрянная пуля в тестировании . . . 15
- 4.9 Пуассоновский Бутстрап . . . 16
- 4.10 Bootstrap CI в Python . . . 16

5 Конверсия и метрики отношений 18
- 5.1 Конверсия: две независимые пропорции . . . 18
- 5.2 Конверсия в Python . . . 18
- 5.3 Ratio-метрики: почему «как есть» опасно . . . 18

6 Итоги и практика 20
- 6.1 Единый процесс . . . 20
- 6.2 Чеклист перед сравнением групп . . . 20
- 6.3 Домашнее задание . . . 20

Глава 1 Зачем аналитике статистика

1.1 Типичный вопрос аналитика

Кейс: новая форма карточки вакансии

После внедрения нового функционала конверсия в отклик выросла с 12.0% до 12.5%. **Это эффект продукта или обычный шум выборки?**

- **Оценка эффекта:** насколько отличаются группы?
- **Неопределённость:** действительно ли наше действие изменило показатели?
- **Решение:** достаточно ли данных для принятия решения?

Простыми словами

Статистика не говорит, что делать. Она описывает вероятность эффекта и риски принятия неверного решения.

1.2 От данных к решению

Аналитика часто отвечает на три вопроса: есть ли разница, насколько мы в ней уверены и хватает ли данных. Оценки «на глаз» недостаточно: шум выборки или внешний шум легко принять за эффект от изменения. Кохави описывает это так: "Получить числа легко, получить числа, которым можно доверять, трудно".

Пример жизненного цикла анализа данных:



Подводный камень

Вывод «Разница статистически значима» без расчётов эффекта, CI, качества данных и понимания контекста бизнеса — неполный вывод.

Аналитик должен не просто посчитать цифры, а понять можно ли им доверять и помочь принять решение, что делать с полученными цифрами дальше.

Глава 2 Гипотезы, ошибки и мощность

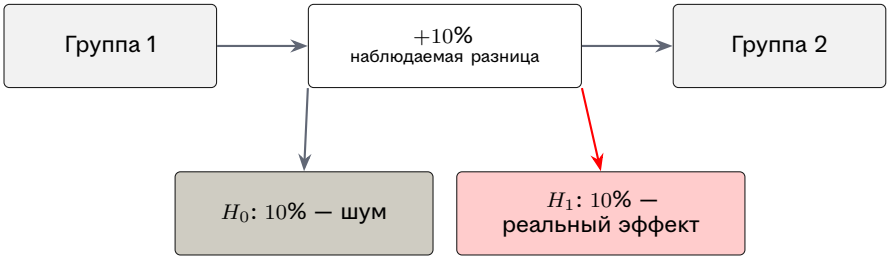
2.1 Язык проверки гипотез

Гипотеза (продуктовая) — обоснованное предположение или догадка, требующая проверки, подтверждения или опровержения.

H_0 **(нулевая гипотеза)** — Различия между группами нет, по умолчанию верна.

H_1 **(альтернатива)** — Различия между группами есть, эту гипотезу мы хотим проверить.

p-value — Вероятность получить наблюдаемую или более экстремальную разницу, при условии, что H_0 верна.



Частые ошибки

p-value **не** равен вероятности правдивости H_0, **не** измеряет размер эффекта и ничего не говорит о его надежности: то есть наблюдаемый результат мог быть получен случайно.

Ошибка I рода — (ложная тревога, ложноположительное срабатывание) – нашли то, чего нет .

Ошибка II рода — (ложный негатив, ложноотрицательное срабатывание) – не нашли то, что есть .



Четыре исхода решения

	H_0 верна	H_1 верна
Не отклонить H_0	верное решение	ошибка II рода (β)
Отклонить H_0	ошибка I рода (α)	верное решение

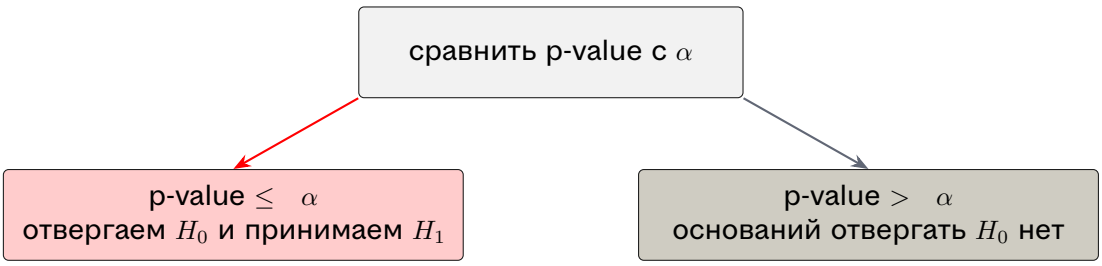
Мы количественно проверяем вероятность отсутвия разницы между группами при верности H_0. Проверка происходит через сравнение p-value с α, уровнем значимости.

α — Уровень значимости или вероятность заметить изменение при условии, что его нет .

$1 - \beta$ — Статистическая мощность - вероятность обнаружения значимого различия при условии, что оно есть .

α — Вероятность совершить ошибку первого рода.

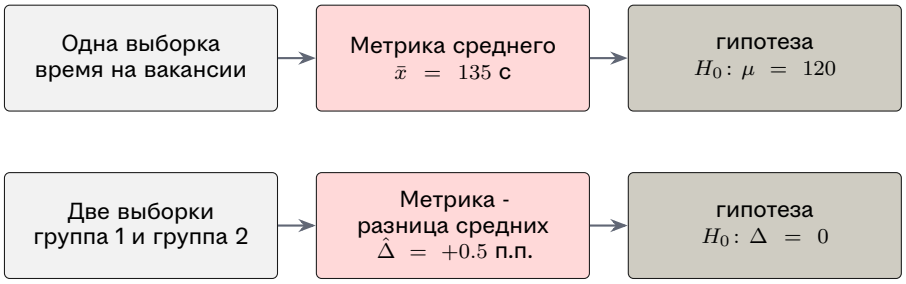
β — Вероятность совершить ошибку второго рода.



Обычно заранее $\alpha = 5\%$ и $1 - \beta = 80\%$: ложно принимаем изменение в 5% случаев и пропускаем полезное в 20%.

2.2 Сначала одна группа и эффект

При проверке гипотезы происходит всегда одно и то же: из данных получаем **одно число** (оценку эффекта) и сравниваем его с **оценкой из гипотезы**. Оценка на одной выборке и двух выборках отличаются только тем, как считаются эти числа.



Одна выборка: среднее срвнивается с заранее заданным числом

Второй группы нет. Есть эталон, который дан заранее. Продукт считает, что среднее время на карточке вакансии равно 120 с. В выборке пользователей получилось $\bar{x} = 135$ с.

- Оценка эффекта - одно число - метрика среднего времени на карточке вакансии, 135 с.
- Гипотеза также представлена одним числом: $H_0: \mu = 120$.
- Вопрос проверки гипотезы: насколько типично наблюдать метрику=135 с,

если истинное среднее и правда 120 с?

Две выборки: считаем разница средних и сверяем её с ожидаемой разницей в H_0

Карточка из первой группы даёт конверсию в отклик 12.0%, карточка из второй группы даёт 12.5%. Проверка гипотезы не сравнивает два распределения между собой, а сравнивает разницу средних с нулем.

- Оценка эффекта - одно число - метрика среднего времени на карточке вакансии, $\hat{\Delta} = +0.5$ п.п.
- Гипотеза также представлена одним числом: $H_0 : \Delta = 0$, где $\Delta = \mu_1 - \mu_2$.
- Вопрос проверки гипотезы: насколько типично наблюдать $\hat{\Delta}$, если истинная разница Δ равна нулю?

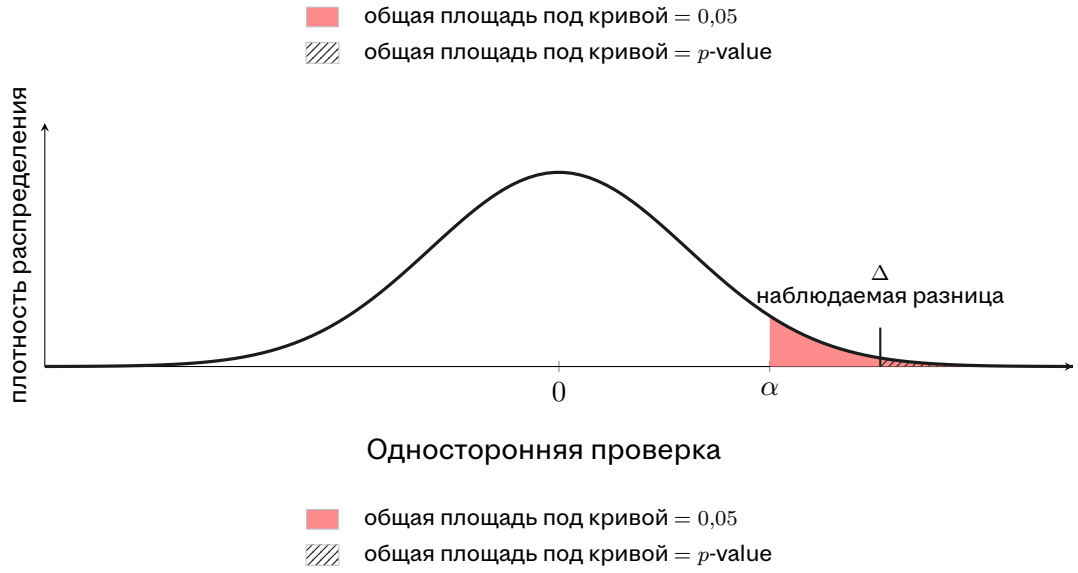
Интересно, что...

Число в нулевой гипотезе не обязано быть нулём.

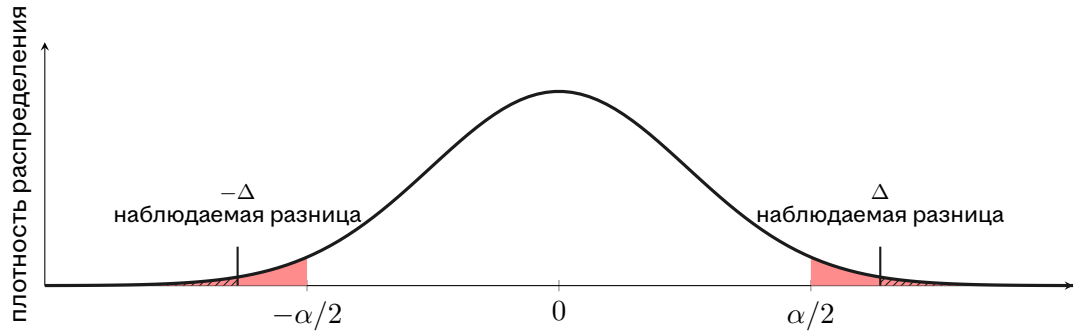
Иногда ожидаемая разница заранее другая. Команда выкатывает изменение, только если прирост конверсии не меньше $+0.5$ п.п. Тогда в H_0 стоит не ноль, а требуемый порог: $H_0 : \Delta = 0.5$. Наблюдаемую разницу $\hat{\Delta} = +0.4$ п.п. сравнивают с $\Delta = 0.5$, а не с 0. Но схема проверки гипотезы не меняется: одна оценка против одного ожидаемого числа в H_0.

2.3 p-value в картинках

Использование p-value для оценки статистической значомсти наблюдеамой разницы (дельты).



Односторонняя проверка



Двусторонняя проверка

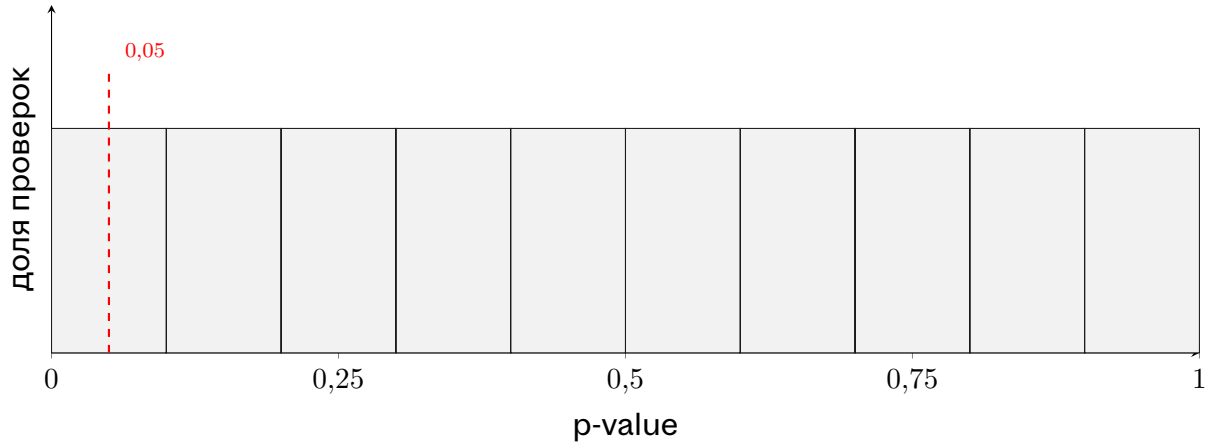
Для двусторонней проверки считаем оба направления эффекта. Для односторонней - только заранее выбранное.

Нюанс

Направление одностороннего теста выбирают до просмотра данных.

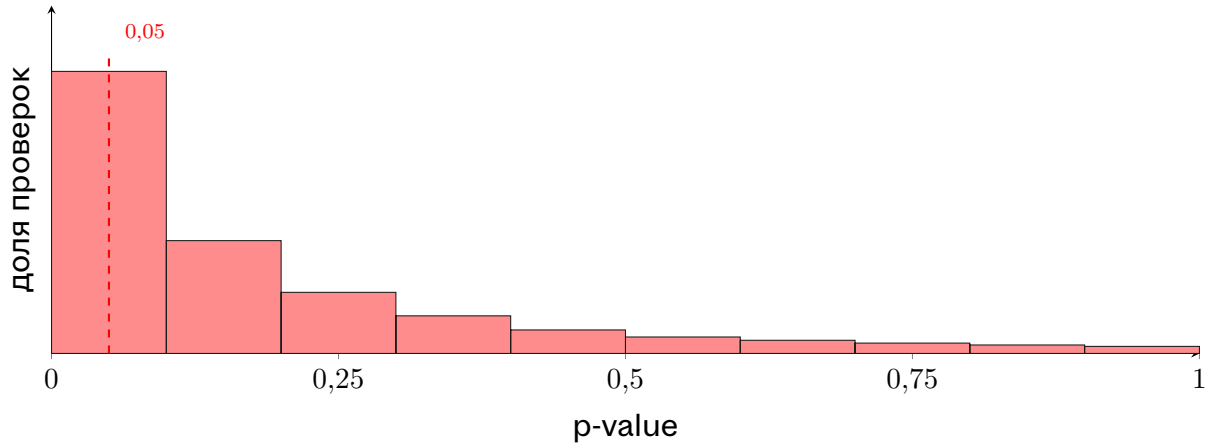
При односторонней проверке статистический критерий проверки значисоти разницы будет срабатывать только в этом заданном направлении. Поэтому на практике обычно используют двустороннюю проверку.

Если H_0 верна, а критерий непрерывный и посчитан правильно, p-value равномерен на отрезке от 0 до 1. Любое значение от 0 до 1 одинаково вероятно. При $\alpha = 0{,}05$ вы отвергаете верную H_0 ровно в 5% таких проверок. Это и есть ошибка I рода. Если много раз прогнать эксперимент, в котором эффекта нет, гистограмма p-value будет плоской, а не горкой у нуля.



Эффекта нет: при верной H_0 гистограмма p-value равномерно распределена. Пунктиром - порог $\alpha = 0{,}05$.

Горка у нуля появляется, когда эффект есть: отметка систематически уезжает в хвост, и маленькие p-value становятся частыми.



Эффект есть: маленькие p-value встречаются чаще, у нуля появляется горка.

2.4 Что делает проверку гипотез чувствительной

Мы стремимся в оценке заметить как можно меньший эффект, чтобы не пропустить полезный эффект. И чем меньше этот эффект, тем тест и чувствительнее. Поэтому важно знать, какие параметры и как влияют на замечаемый эффект.

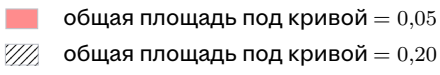
$$\text{тест чувствительнее, если } \sim \frac{\sqrt{n}}{\sigma} \times \frac{1}{\alpha, \beta}$$

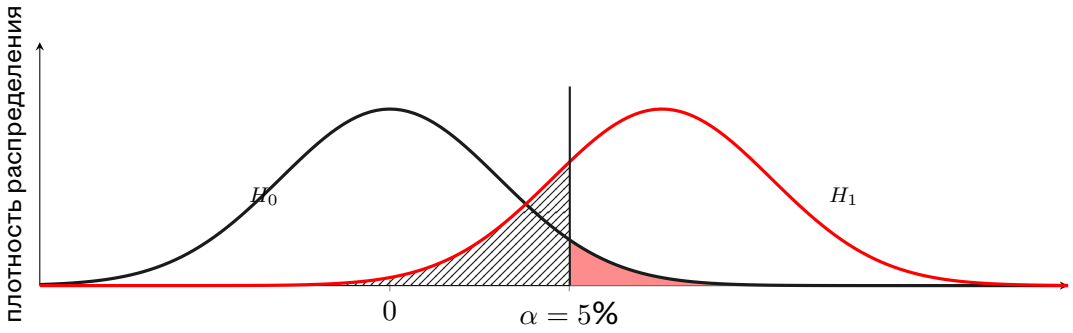
Итого замечаемый эффект тем заметнее, чем:

- больше размер выборки n;
- меньше разброс (шум/ско) σ;
- меньше заранее выбранный уровень значимости α;
- больше мощность 1-β.

При этом при малом числе наблюдений мы будем получать большие эффекты от любых изменений, а при большом числе наблюдений мы будем получать маленькие эффекты от таких же изменений. Также интересный факт, что при увеличении среднего значения как правило разброс метрики растет с меньшей скоростью.

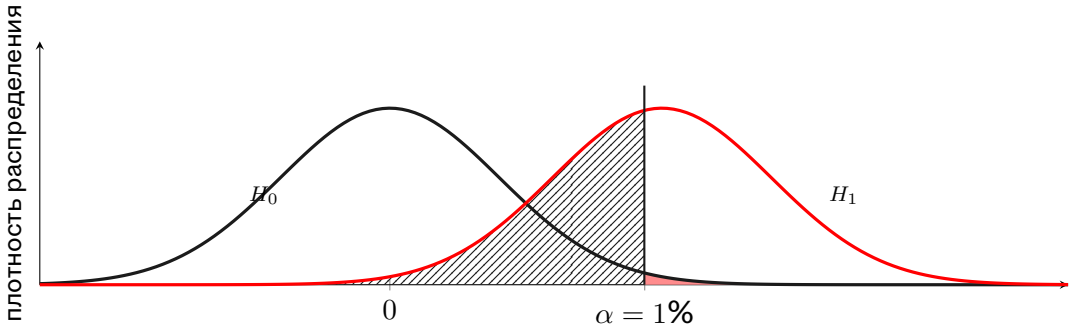
К сожалению, мы не может одновременно свести и α, и β к нулю. Поэтому мы должны выбрать компромисс между этими двумя ошибками. Обычно мы выбираем $\alpha = 0.05$ и $\beta = 0.2$. Это означает, что мы будем отвергать верную H_0 в 5% случаев, и пропускать полезный эффект в 20% случаев.





$\alpha = 5\%$, $\beta = 20\%$, мощность 80%.

общая площадь под кривой $= 0{,}01$
общая площадь под кривой $= 0{,}4364$



$\alpha = 1\%$, $\beta = 43{,}64\%$, мощность $56{,}36\%$.

Глава 3 Доверительные интервалы

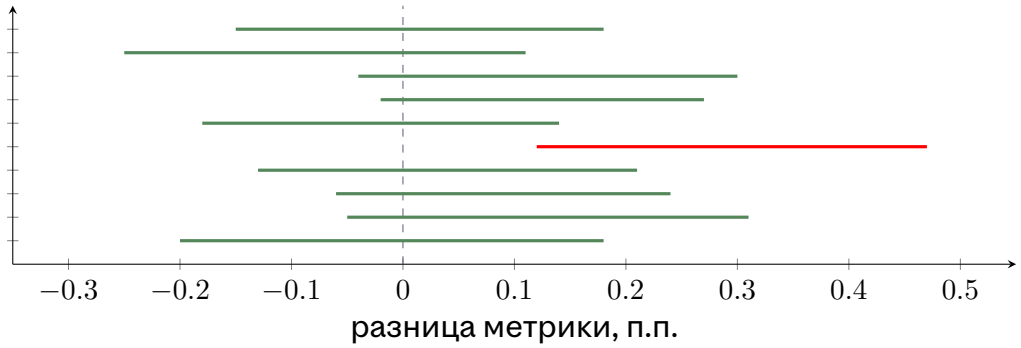
3.1 Эффект без интервала - неполный ответ

Доверительный интервал n% — (Confidence Interval) Диапазон, который покрывает истинную разницу в n% случаев новых выборок из той же генеральной совокупности.

Простыми словами

Если много раз заново набрать такие же выборки и каждый раз построить интервал тем же способом, примерно n раз из 100 интервалов накроют истинную разницу. Каждый раз будут получаться разные границы ДИ.

Пример расчёта доверительного интервала для 10 выборок из одной ГС



Для разницы средних $\Delta = \mu_1 - \mu_2$ доверительный интервал выглядит так:

$$\widehat{\Delta} \pm t_{1-\alpha/2,\nu} \cdot SE(\widehat{\Delta})$$

где

- $\widehat{\Delta}$ - это точечная оценка эффекта: разница средних, посчитанная по выборке;
- $SE(\widehat{\Delta})$ - это стандартная ошибка этой оценки, то есть её шум;
- $t_{1-\alpha/2,\nu}$ - это коэффициент из t-распределения: насколько далеко отступить от оценки в каждую сторону. При большом n типично $t \approx 1{,}96$;
- α - это уровень значимости. Для интервала 95% берут $\alpha = 0{,}05$, и квантиль считается в точке $1 - \alpha/2$;

Полезная интерпретация

Если 0 лежит внутри CI, то оснований считать H_0 отвергнутой нет.

3.2 Стандартная ошибка среднего

Стандартная ошибка среднего - это стандартное отклонение самого среднего: насколько оценка $\bar{x}$ обычно сдвигается от выборки к выборке, если истинное среднее не меняется. Мера неопределенности криетрия.

$$SE(\bar{x}) = \frac{\sigma}{\sqrt{n}}$$

где

- $SE(\bar{x})$ - это стандартная ошибка выборочного среднего;
- σ - это стандартное отклонение одного наблюдения в генеральной совокупности;
- n - это размер выборки.

3.3 Практическая интерпретация

Доверительный интервал показывает, какие значения эффекта ещё согласуются с данными и моделью. Кохави рекомендует всегда давать интервал для разницы, а не только вердикт «значимо / нет». Так мы получаем более полную информацию об эффекте.

Использование для интерпретации только p-value

- «$p = 0.03$, значимо» трудно интерпретировать;
- Не видно масштаба эффекта;
- Не видно точности оценки эффекта.

Использование дополнительно Доверительного интервала

- Видим ширину интервала, например в чувствительном тесте [0.009, 0.013], в зашумленных данных возможно увидеть [0.01, 0.91];
- Более точная интерпритация эффекта: эффект по метрике от 0.9%.

Простыми словами

Вопрос бизнесу: «достаточно ли даже нижней границы эффекта, чтобы оправдать изменение?»

Глава 4 Методы для статистических проверок

4.1 Центральная предельная теорема

Центральная предельная теорема (ЦПТ) утверждает, что распределение среднего из независимых случайных величин с конечными дисперсиями стремится к нормальному распределению, когда количество слагаемых стремится к бесконечности.

Это означает, что для больших n среднее из независимых случайных величин близко к нормальному распределению, независимо от распределения самих величин.

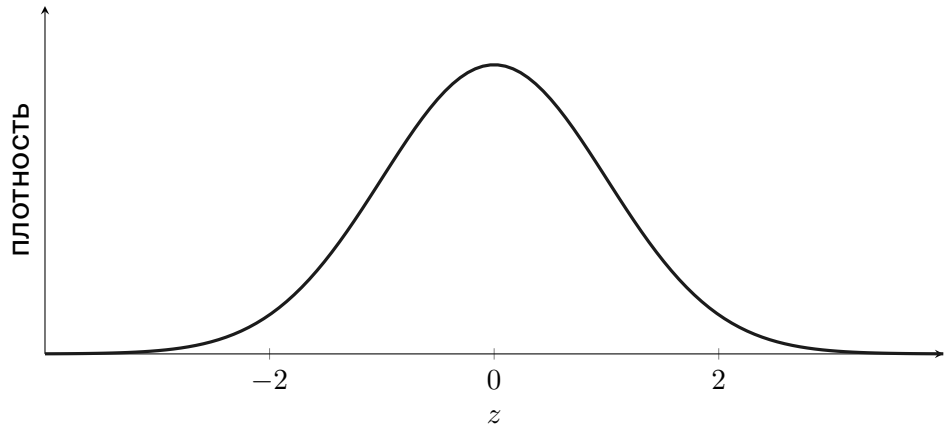
4.2 z-test

z-test — проверка гипотезы о среднем, когда генеральное стандартное отклонение σ известно. Статистика показывает, на сколько стандартных ошибок оценка $SE(\bar{x})$ от гипотезы об эффекте μ_0. Порог для отклонения гипотезы H_0 берут из стандартного нормального закона: при $\alpha = 0.05$ это 1.96.

В общем случае z-распределение - это нормальное распределение с центром в 0 и единичной дисперсией.

z_i — одно наблюдение. Для каждого пользователя считают, на сколько его значение ушло от среднего, в единицах разброса одного наблюдения:

$$z_i = \frac{x_i - \mu}{\sigma}$$



Это z-распределение.

Случай одной выборки, когда нулевая гипотеза говорит, что среднее равно заданному числу $H_0 : \mu = \mu_0$:

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} = \frac{\bar{x} - \mu_0}{SE(\bar{x})}$$

Случай двух выборок, когда нулевая гипотеза говорит, что разница средних равна заданному числу $H_0 \colon \mu_T - \mu_C = \delta_0$ (часто $\delta_0 = 0$):

$$z = \frac{(\bar{x}_2 - \bar{x}_1) - \delta_0}{\sigma\sqrt{1/n_T + 1/n_C}} = \frac{(\bar{x}_2 - \bar{x}_1) - \delta_0}{SE(\bar{x}_2 - \bar{x}_1)}$$

Требования z-test'a:

- Независимые наблюдения;
- Выборочные средние распределены нормально (при достаточно большом числе наблюдений n по ЦПТ среднее распределено нормально);
- Генеральное стандартное отклонение σ действительно известно.

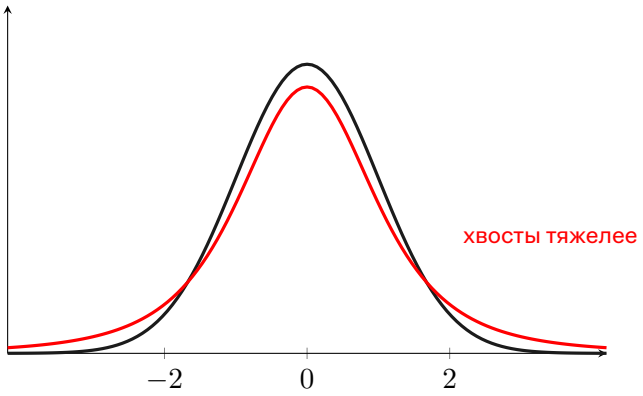
4.3 t-test

t-test, или критерий Стьюдента, — это та же проверка гипотезы о среднем, что и z-test, но генеральное σ неизвестно. Вместо него в знаменатель ставят выборочное среднеквадратическое отклонение s.

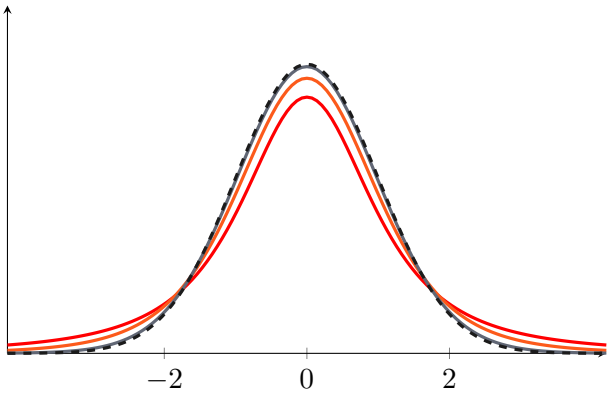
Подводный камень

z-test требует известное генеральное стандартное отклонение σ. Но в продуктовых задачах этот кейс невозможен, σ оценивается по данным, поэтому нужен t-test.

У распределения Стьюдента хвосты тяжелее, чем у нормального распределения с центром в 0 и единичной дисперсией. Ширину хвостов задаёт число степеней свободы: чем меньше выборка, тем они тяжелее. Но при большом n распределение Стьюдента почти совпадает со стандартным нормальным.



Чёрная кривая — нормальное. Красная — t при малом n. Хвосты тяжелее.



При росте n t сходится к нормальному. Красная $n = 3$, оранжевая $n = 6$, серая $n = 31$, пунктир — нормальное.

В целом все формулы похожи на формулы z-test'a, только вместо σ используется s.

t_i - одно наблюдение в распределении Стьюдента:

$$t_i = \frac{x_i - \mu}{s}$$

Случай одной выборки, когда нулевая гипотеза говорит, что среднее равно заданному числу $H_0 : \mu = \mu_0$:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n-1}} = \frac{\bar{x} - \mu_0}{SE(\bar{x})}$$

Порог берут из распределения Стьюдента с $n - 1$ степенями свободы. Здесь $SE(\bar{x}) = s/\sqrt{n-1}$.

Случай двух выборок, когда нулевая гипотеза говорит, что разница средних равна заданному числу $H_0 : \mu_2 - \mu_1 = \delta_0$ (часто $\delta_0 = 0$):

$$t = \frac{(\bar{x}_2 - \bar{x}_1) - \delta_0}{s_p\sqrt{1/n_2 + 1/n_1}} = \frac{(\bar{x}_2 - \bar{x}_1) - \delta_0}{SE(\bar{x}_2 - \bar{x}_1)}$$

где s_p — общая оценка стандартного отклонения по двум группам. Порог берут из распределения Стьюдента с $n_2 + n_1 - 2$ степенями свободы.

Требования t-test'a:

- Независимые наблюдения;
- Выборочные средние распределены нормально (при достаточно большом числе наблюдений n по ЦПТ среднее распределено нормально);
- Гомогенность дисперсий между группами (примерное равенство).

4.4 Welch t-test: сравниваем средние

На практике дисперсии редко бывают точно равны, поэтому используют Welch t-test. Этот критерий не требует гомогенности дисперсий и оценивает степени свободы приближённо.

$$t = \frac{\bar{x}_2 - \bar{x}_1}{\sqrt{s_2^2/n_2 + s_1^2/n_1}}$$

Требования Welch t-test'a:

- Нужны независимые наблюдения и репрезентативные группы.
- При достаточном n среднее часто приблизительно нормально по ЦПТ.

4.5 t-test: когда хорош, а когда нет

Плюсы

- понятная цель: разница средних;
- мощен при корректных предпосылках;
- CI и эффект легко объяснить.

Ограничения

- чувствителен к сильным выбросам при малом n;
- не решает проблему зависимости наблюдений;
- среднее не всегда «типичный пользователь».

Подводный камень

Проверка нормальности с большим n почти всегда пройдёт отлично. Важнее репрезентативность групп, выбросы и практическая устойчивость вывода.

4.6 t-test в Python

```
from scipy.stats import ttest_ind

# Двенезависимыегруппы ; Welch —безопасныйвариантработыфункциипоумолчанию
result = ttest_ind(control, test,
                   equal_var=False,
                   alternative="two-sided")
print(result.statistic, result.pvalue)
```

Совет

Сохраняйте вместе с p-value разницу средних, CI, размер групп и правила исключения наблюдений.

```
import numpy as np

rng = np.random.default_rng(7)

# Независимыегруппы , дисперсииразные—дляэтогоиберут Welch
control = rng.normal(loc=10.0, scale=2.0, size=80)
test = rng.normal(loc=10.8, scale=2.6, size=75)

print(f"control: n={control.size}, mean={control.mean():.3f}, s={control.std(ddof=1)
    :.3f}")
print(f"test:    n={test.size}, mean={test.mean():.3f}, s={test.std(ddof=1):.3f}")
```

```
control: n=80, mean=9.647, s=1.781
test:    n=75, mean=10.404, s=2.255
```

```python
from scipy.stats import ttest_ind

# Двенезависимыегруппы ; Welch —безопасныйвариантработыфункциипоумолчанию
result = ttest_ind(control, test,
                   equal_var=False,
                   alternative="two-sided")
print(result.statistic, result.pvalue)

# Рядомс p-value: разницасредних , CI иразмерыгрупп
diff = control.mean() - test.mean()
ci = result.confidence_interval(confidence_level=0.95)
print(f"diff control-test = {diff:.3f}")
print(f"95% CI = [{ci.low:.3f}, {ci.high:.3f}]")
print(f"n_control = {control.size}, n_test = {test.size}")
```

-2.3081093921831903 0.022450133971285608
diff control-test = -0.757
95% CI = [-1.404, -0.109]
n_control = 80, n_test = 75

4.7 Критерий Манна-Уитни

Критерий Манна-Уитни - это непараметрический критерий для двух независимых выборок. Он используется для проверки гипотезы о том, что две выборки имеют одно и то же распределение.

Нулевая гипотеза здесь про распределения и вероятность превосходства: случайное наблюдение из теста оказывается не чаще выше случайного наблюдения из контроля. Это не проверка разницы средних или медианы.

Важно помнить

Критерий Манна-Уитни не проверяет среднее. Не даёт интерпретируемый в числах эффект.

$$U_T = R_T - \frac{n_T(n_T+1)}{2}$$

секунды	2	4	5	7	9	11
группа	контроль	контроль	тест	контроль	тест	тест
ранг	1	2	3	4	5	6

Красным выделен тест. Ранги теста: 3, 5 и 6. $R_T = 14$, $U_T = 8$ из 9 пар.

- Объединяем наблюдения, заменяем значения рангами; R_T - сумма рангов теста.
- Уместен для независимых порядковых данных, как альтернативная проверка при тяжёлых выбросах или в совокупности с бакетинг-методами.
- Гипотеза относится к распределениям/вероятности превосходства, а не к разнице средних.

- Не даёт интерпретируемый в числах эффект.
- Непараметрический критерий менее требователен, но всё ещё обязательны независимость данных и понимание смысла сравнения распределений.

Подводный камень

На практике сегодня почти не используется в бигтехе.

Те же шесть наблюдений, что в таблице выше. Первым аргументом идёт тест, поэтому statistic — это U теста, в таблице $U_T = 8$.

```
from scipy import stats

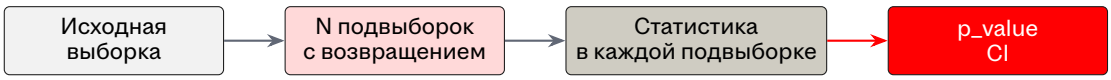
control = [2, 4, 7]
test = [5, 9, 11]

result = stats.mannwhitneyu(test, control, alternative="two-sided")
print(result.statistic, result.pvalue)
```

8.0 0.2

4.8 Bootstrap: серебрянная пуля в тестировании

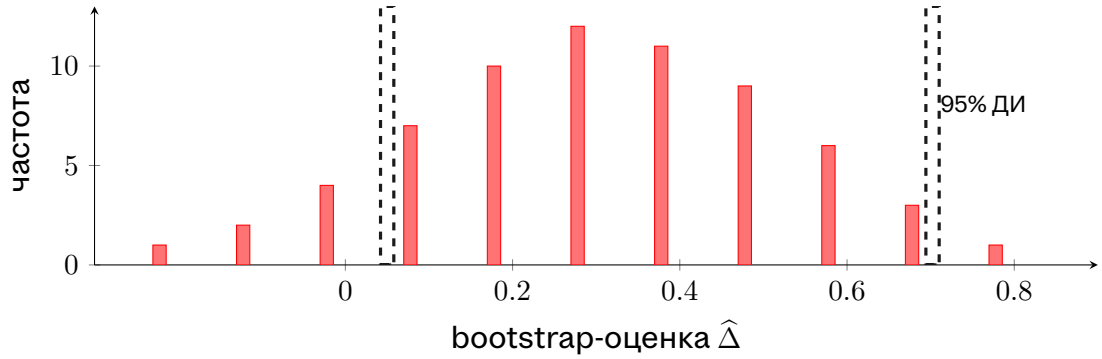
Бутстрап — это способ оценить распределение статистики по уже собранной выборке: из неё много раз берут выборки того же размера с возвращением, каждый раз заново считают ту же статистику, и по этому распределению читают разброс оценки. Метод используется для оценки статистических свойств выборки и построения доверительных интервалов.



- Гибок: можно оценивать среднее, медиану, перцентиль, разницу метрик.
- Не исправляет смещение, зависимость наблюдений или нерепрезентативную выборку.
- Необходимы большие вычислительные ресурсы.
- При малом n копирует те же точки и может врать.
- Для обычного среднего независимых пользователей t-test мощнее и проще.

p-value в бутстрапе - это доля подвыборок, в которых разница получилась не меньше наблюдаемой, если верна H_0.

Bootstrap-распределение разницы средних



Пунктир — 95% доверительный интервал (2.5-й и 97.5-й процентили). Данные на слайде синтетические.

4.9 Пуассоновский Бутстрап

Мы можем считать «сколько раз в псевдовыборку попадет наше наблюдение». Такая величина будет иметь биномиальное распределение вида:

$$k = Binomial(n, 1/n)$$

Считать «сколько раз наблюдение попадет в выборку» намного быстрее, чем последовательно проверять «попало - не попало» много раз. И несмотря на то, что не все выборки получатся в точности одинаковой длины, нам это не помешает. Ускоримся еще немножко. При большой длине выборки наше биномиальное распределение – почти то же самое, что распределение Пуассона:

$$k = Binomial(n, 1/n) \sim Poisson(1)$$

Тут, как видите, никакой зависимости от n нет. И считается оно чуть побыстрее. Итого: Пуассоновский бутстрап - это бутстрап, который использует распределение Пуассона для подсчета количества появлений наблюдения в подвыборке.

4.10 Bootstrap CI в Python

```python
import numpy as np
from scipy.stats import bootstrap

def diff_mean(x, y, axis=-1):
    return np.mean(y, axis=axis) - np.mean(x, axis=axis)

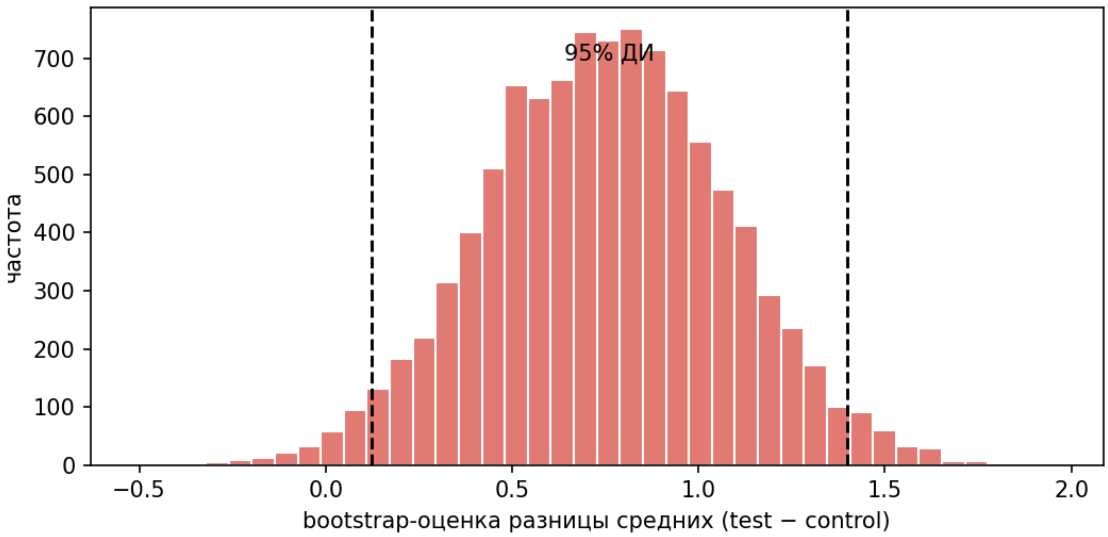
res = bootstrap((control, test), diff_mean,
                n_resamples=9_999, method="BCa",
                random_state=42)
print(res.confidence_interval)
```

Те же группы control и test, что в примере t-test выше. diff_mean считает среднее теста минус среднее контроля.

ConfidenceInterval(low=np.float64(0.12210315664540218), high=np.float64(1.400161275719026))

```python
import matplotlib.pyplot as plt

ci = res.confidence_interval
fig, ax = plt.subplots(figsize=(7.2, 3.6))
ax.hist(res.bootstrap_distribution, bins=40, color="#E07A72", edgecolor="white")
ax.axvline(ci.low, color="black", linestyle="--", linewidth=1.4)
ax.axvline(ci.high, color="black", linestyle="--", linewidth=1.4)
ax.set_xlabel("bootstrapоценка- разницысредних  (test - control)")
ax.set_ylabel("частота")
ymin, ymax = ax.get_ylim()
ax.text((ci.low + ci.high) / 2, ymax * 0.92, "95% ДИ", ha="center", va="top")
fig.tight_layout()
fig.savefig("assets/bootstrap-diff-means.png", dpi=150)
plt.show()
```



Пунктир - границы 95% ДИ. Столбики - бутстрап-оценки разницы средних.

Глава 5 Конверсия и метрики отношений

5.1 Конверсия: две независимые пропорции

Конверсия - доля успехов: пользователь совершил целевое действие или нет. Используем тест двух независимых пропорций, который по сути является z-test для разницы двух пропорций. Пусть $\hat{p}_1 = x_1/n_1$, $\hat{p}_2 = x_2/n_2$. Для $H_0 : p_1 = p_2$:

$$z = \frac{\hat{p}_2 - \hat{p}_1}{\sqrt{\hat{p}(1-\hat{p})(1/n_2 + 1/n_1)}}, \qquad \hat{p} = \frac{x_1 + x_2}{n_1 + n_2}$$

- Подходит для бинарного исхода при независимых наблюдениях.

  На больших выборках иногда считают t-test с поправкой или score-тестом.

5.2 Конверсия в Python

```python
from statsmodels.stats.proportion import (
    test_proportions_2indep,
)

result = test_proportions_2indep(
    count1=120, nobs1=1_000,
    count2=125, nobs2=1_000,
    compare="diff", method="score"
)
print(result.statistic, result.pvalue)
```

Тот же вопрос формулой z-test. Контроль: 120 успехов из 1000, тест: 125 из 1000.

```python
import math
from scipy.stats import norm

x_c, n_c = 120, 1_000
x_t, n_t = 125, 1_000
p_c, p_t = x_c / n_c, x_t / n_t
p = (x_c + x_t) / (n_c + n_t)
z = (p_t - p_c) / math.sqrt(p * (1 - p) * (1 / n_t + 1 / n_c))
pvalue = 2 * norm.sf(abs(z))
print(f"p_C={p_c:.3f}, p_T={p_t:.3f}, p={p:.4f}")
print(z, pvalue)
```

p_C=0.120, p_T=0.125, p=0.1225
0.34100708287592074 0.733098249628225

5.3 Ratio-метрики: почему «как есть» опасно

- Пример: CTR $= \frac{\text{клики}}{\text{показы}}$, средний чек $= \frac{\text{выручка}}{\text{заказы}}$.
- Числитель и знаменатель случайны и обычно зависимы.

И вот эта зависимость делает невозможным использовать классические статистические методы напрямую. Нам нужно что-то другое. Но это вы разберёте на лекции посвященной ratio-метркиам.

Глава 6 Итоги и практика

6.1 Единый процесс



Итог процесса. Получаем вопрос от бизнеса → Переводим этот вопрос в метрику и выбираем единицу наблюдения → Формируем гипотезу об эффекте, который му хотим увидеть на выбранной метрике по выбранной единице наблюдения → Выбираем критерий под метрику, собираем данные → Считаем наблюдаемый эффект, доверительный интервал этого эффекта и p-value, то есть понимаем, насколько случайный мы наблюдаем эффект → Принимаем решение. Описываем выводы и даём рекомендации.

Простыми словами

Хорошее статистическое решение можно воспроизвести: понятны вопрос, данные, допущения, метод и границы вывода.

6.2 Чеклист перед сравнением групп

1. Сформулировать метрику, единицу наблюдения и минимально полезный эффект.
2. Зафиксировать H_0, H_1, α, альтернативу и правила очистки.
3. Проверить независимость, выбросы, размеры групп и качество данных.
4. Выбрать статистический критерий под метрику.
5. Сообщить эффект, CI, p-value, ограничения и решение.

6.3 Домашнее задание

Формат

Домашнее задание принимается в виде ноутбука в формате ipynb.

1. Продукт считает, что среднее время на карточке вакансии равно 120 секунд. Собрали $n = 100$ пользователей, $\bar{x} = 124$ секунды. Разброс одного наблюдения в генеральной совокупности известен заранее: $\sigma = 25$ секунд. Сформулируйте H_0. Посчитайте, на сколько стандартных ошибок оценка ушла от 120. Решите, есть ли основание отвергать H_0.

2. Первая группа: $n_1 = 40$, $\bar{x}_1 = 50$, выборочное среднеквадратическое отклонение $s_1 = 10$. Вторая группа: $n_2 = 40$, $\bar{x}_2 = 55$, $s_2 = 10$. Генеральные разбросы двух групп неизвестны и равными их считать не нужно. Посчитайте разницу средних и 95% доверительный интервал для неё. Напишите, попадает ли 0 в интервал и какой самый маленький эффект ещё согласуется с данными (который не будет опровергать H_0).

3. Первая группа: 90 откликов на 1000 показов карточки. Вторая группа: 120 откликов на 1000 показов. Каждый показ относится к своему пользователю,

группы независимы. Сформулируйте H_0 про две конверсии. Посчитайте разницу в процентных пунктах и статистику критерия для двух долей. Решите, есть ли основание отвергать H_0.

Как набирать выборки в задачах 4–7. Используйте генератор случайных чисел из numpy: сначала rng = np.random.default_rng(7), потом rng.normal(mu, sigma, size). Здесь mu — среднее, sigma — разброс одного наблюдения, size — сколько наблюдений набрать. Так же записывается $N(\mu, \sigma)$: первое число — среднее, второе — разброс одного наблюдения. Число в скобках после default_rng — стартовое число генератора. При одном и том же числе выборки каждый раз получаются одинаковыми, поэтому результат можно повторить. Возьмите любое число и напишите, какое взяли.

4. Повторите эксперимент 2000 раз. В каждом повторе заново наберите две группы по $n = 200$ наблюдений из одного и того же $N(0, 1)$. На каждой паре групп посчитайте t Уэлча и его p-value. Нарисуйте распределение p-value. Напишите, какую форму оно имеет и почему.

5. Повторите эксперимент 1000 раз. Первая группа каждый раз из $N(0, 1)$, $n = 60$. Вторая из $N(1, 1)$, тоже $n = 60$; после этого два её наблюдения замените на -50. На каждой паре групп посчитайте разницу средних, t Уэлча, U Манна–Уитни для первой группы и p-value обоих критериев. Нарисуйте распределения t и U. Нарисуйте распределения p-value обоих критериев и отметьте на них 0,05. Сравните, где они сосредоточены. Какое решение при двустороннем пороге 5% принимает каждый критерий? Совпали выводы или разошлись? Объясните, почему.

6. Один раз наберите первую группу из $N(10, 2)$, $n_1 = 80$, и вторую из $N(10{,}8, 2{,}6)$, $n_2 = 75$. Посчитайте 95% доверительный интервал Уэлча для разницы средних «вторая минус первая» и p-value критерия Уэлча. Решите, есть ли основание отвергать H_0 при двустороннем пороге 5%. Напишите, попадает ли 0 в интервал и какой самый маленький эффект ещё согласуется с данными (не отвергает H_0).

7. Возьмите те же две группы, что в предыдущей задаче. 2000 раз заново соберите выборки того же размера: каждый раз берите наблюдения из уже полученных групп с возвращением (в numpy для этого есть rng.choice с параметром replace=True) и заново считайте разницу средних. Нарисуйте распределение этих разниц. 95% интервал бутстрапа — границы, отсекающие по 2,5% значений с каждого края. Сравните эти границы с интервалом из предыдущей задачи. Отдельно посчитайте, в какой доле таких повторных выборок разница получилась не больше нуля. Можно ли эту долю назвать p-value? Объясните.